

Practica 12: Teorema del Límite Central y Teorema de Glivenko-Cantelli

En esta práctica verificarán computacionalmente la validez de dos grandes teoremas de la teoría de Probabilidad: el Teorema del Límite Central y el Teorema de Glivenko-Cantelli.

Ejercicio 1:

En este ejercicio verificaremos computacionalmente el Teorema del Límite Central para las distribuciones Uniforme, Exponencial y Pareto así que comencemos por recordarlo.

Teorema (Teorema del Límite Central):

Sea $X_1, X_2, \dots$ una sucesión infinita de variables aleatorias independientes e idénticamente distribuidas con media μ y varianza finita σ^2 . Entonces la función de distribución de la variable aleatoria

$$Z = \frac{(X_1 + \dots + X_n) - n\mu}{\sqrt{n\sigma^2}}$$

tiende a la función de distribución normal estándar cuando n tiende a infinito.

Parte 1:

Como recordarán, en la práctica anterior aprendieron a simular variables aleatorias con distribución Exponencial y Pareto usando únicamente la función `np.random.uniform()` de numpy. En esta parte simplemente deberán copiar y pegar las funciones de la práctica anterior para simular esas variables.

```
import numpy as np
```

Aquí van tus funciones:

Parte 2:

Ahora deberán crear una función que calcule la variable aleatoria Z del teorema del límite central. Su función deberá recibir como parámetros una lista con una muestra de variables aleatorias idénticamente distribuidas, un real que represente μ y un real que represente σ^2 y deberá regresar el valor de Z .

Parte 3:

Ya tenemos todo lo necesario para poner a prueba el Teorema del Límite central. En esta parte deberán hacer lo siguiente para las distribuciones **Uniforme(0,1)**, **Exponencial($\lambda=2$)** y **Pareto($\alpha=1, c=1$)**, **Pareto($\alpha=2, c=1$)**, **Pareto($\alpha=3, c=2$)**:

1. Generar 1,000 variables aleatorias $Z_n = \frac{\sum_{i=1}^n x_i - n\mu}{\sqrt{n\sigma^2}}$, usando $n=1,000$ variables aleatorias $X_1, X_2, \dots, X_n$ para cada una (son v.a.i.i.d).

$$\frac{\sum_{i=1}^{1000} x_i - n\mu}{\sqrt{n\sigma^2}}, \frac{\sum_{i=1}^{1000} x_i - n\mu}{\sqrt{n\sigma^2}}, \dots, \frac{\sum_{i=1}^{1000} x_i - n\mu}{\sqrt{n\sigma^2}}$$

1. Graficar el histograma de las variables aleatorias Z_n .
2. Graficar sobre el histograma la función de densidad de la normal estándar.

$$f_{normal}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \text{ para } x \in (-\infty, \infty)$$

NOTA:

$$X \sim Unif(0,1)$$

$$E[X] = \frac{1}{2} \text{Var}[X] = \frac{1}{12}$$

$$X \sim exp(\lambda)$$

$$E[X] = \frac{1}{\lambda} \text{Var}[X] = \frac{1}{\lambda^2}$$

$$X \sim \text{pareto}(\alpha, c)$$

$$E[X] = \frac{\alpha c}{\alpha - 1} \text{ para } \alpha > 1 \text{Var}[X] = \frac{\alpha c^2}{(\alpha - 1)^2(\alpha - 2)}$$

Si no esta determinada la esperanza o varianza usa la estimación muestral:

$$\mu = \frac{\sum_{i=1}^n x_i}{n} \sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

para listas puedes usar

`lista.mean(), lista.var()`

para arreglos de numpy

`np.mean(array), np.var()`

`import matplotlib.pyplot as plt`

Ejercicio 2:

En este ejercicio verificaremos computacionalmente el Teorema de Glivenko-Cantelli para las distribuciones Uniforme, Exponencial y Pareto. Comencemos por recordar la definición de la función de distribución empírica:

Definición (Función de Distribución Empírica):

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con función de distribución (f.d.) F . Dada la muestra, definimos la función de distribución empírica (f.d.e.) $\hat{F}_n$ por

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n 1_c(X_i) = \frac{1}{n} \# \{i: X_i \leq x\}$$

Ahora recordemos que nos dice el Teorema de Glivenko-Cantelli

Teorema (Glivenko-Cantelli):

Sea $X_1, \dots, X_n$ una colección de variables aleatorias independientes con distribución común F y sea $\hat{F}_n(x) = \hat{F}_n(x, \omega)$ la función de distribución empírica correspondiente. Entonces

$$\sup_x |\hat{F}_n(x) - F(x)| \rightarrow 0$$

con probabilidad 1.

Parte 1:

Primero deberán programar la función de distribución empírica en general. La idea es que la función reciba como parámetros a x , la cual puede ser variable, y a X (una lista con la muestra aleatoria) la cual no varía.

Parte 2:

En esta parte veremos la convergencia de la distribución empírica a la distribución analítica. Deberán repetir el siguiente procedimiento para la **Uniforme(0,1)**, **Exponencial(2)** y **Pareto(3,2)**:

1. Definir una función que calcule la función de distribución analítica de la distribución. Esta debe recibir un real x y regresar un valor entre 0 y 1.
2. Generar tres muestras aleatorias: una de tamaño 10, una de tamaño 100 y una de tamaño 1000.
3. Para cada una de las muestras generadas hacer una gráfica en la que se compare la función de distribución analítica con la distribución empírica.